INPE
PGCAP

Programa
Queimadas

AVISO DE PROPRIEDADE INTELECTUAL:

É vedada a distribuição ou utilização do conteúdo sem a autorização expressa, por escrito, do autor.

É permitida a manutenção e utilização por parte dos alunos da disciplina Métodos de Otimização, ministrada pelo autor do material.

Para referenciar o material, utilizar:

CARVALHO, F. G. M. Notas de aula da disciplina Métodos de Otimização. São José dos Campos - SP, 2026.

INPE
PGCAP

Programa
Queimadas

Métodos de Otimização

Estratégias Baseadas em Derivadas

Prof. Fabrício Galende Marques de Carvalho

2026/3º Período

OBJETIVOS DA UNIDADE

- ✓ Discutir a relação de existência de ótimos e derivadas de uma função.
- ✓ Familiarizar o aluno com os métodos de otimização que utilizam derivada, em especial os métodos do gradiente e gradiente estocástico.
- ✓ Familiarizar o aluno com as variantes modernas dos métodos baseados em derivada, incluindo Adam, RMSProp, Adagrad e AdamW.
- ✓ Aplicar os conceitos estudados à resolução de problemas simples e de sensoriamento remoto.

INPE
PGCAP

Programa
Queimadas

Estrutura da Unidade

1. Condição de otimalidade
2. Método da descida do gradiente
   a. Intuição Geral
   b. Derivação Para o Caso Univariável
   c. Extensão Para o Caso Multivariável
   d. Detalhes de Implementação
   e. Descrição Algorítmica
   f. Estudo de Caso: Regressão Linear
   g. Considerações Adicionais

Estrutura da Unidade

3. Algoritmo do Gradiente Estocástico
   a. Conceito de *Mini-Batch*
4. Algoritmo do gradiente estocástico com momento
5. Algoritmo do gradiente com estimação adaptativa de momento (Adam)
6. Variantes: RMSProp, Adagrad e AdamW
7. Estudo de Caso: Detecção de vegetação usando bandas visíveis (RGB)
8. Exercícios e problemas

INPE
PGCAP

Programa
Queimadas

1. Condição de otimalidade

Dada uma função *f(x)*, que possui um mínimo (ou um máximo) local em um determinado ponto *x** no interior de seu domínio e considerando que a derivada f′*(x)* é definida em x*, então, necessariamente, *f′(x*) = 0.*

Prova:

Se a derivada *f′(x)* é definida em *x**, então, por definição

$$f'(x^*) = \lim_{h \to 0} \frac{f(x^* + h) - f(x^*)}{h}$$

1. Condição de otimalidade

Como *f(x*)* é um mínimo local, então, na vizinhança de x* tem-se

$$f(x^* + h) \geq f(x^*)$$

que pode ser reescrito como

$$f(x^* + h) - f(x^*) \geq 0$$

INPE
PGCAP

Programa
Queimadas

1. Condição de otimalidade

A existência do limite que define a derivada no otimizador implica, necessariamente, na existência e igualdade dos limites laterais, definidos por

$$f'(x^*) = \lim_{h \to 0^+} \frac{f(x^* + h) - f(x^*)}{h} \geq 0$$

$$f'(x^*) = \lim_{h \to 0^-} \frac{f(x^* + h) - f(x^*)}{h} \leq 0$$

que só é possível se *f'(x*) = 0*. Logo, se a função possui um mínimo e tem derivada definida nesse mínimo, então essa derivada é igual a zero.

1. Condição de otimalidade

A consequência do resultado anterior é que se a função é contínua em um determinado intervalo fechado, os candidatos a pontos de mínimo (ou máximo) são:

- Pontos interiores ao intervalo onde a derivada é nula.
- Pontos interiores ao intervalo onde a derivada não é definida (e.g., uma quina, uma cúspide).
- Extremos do intervalo.

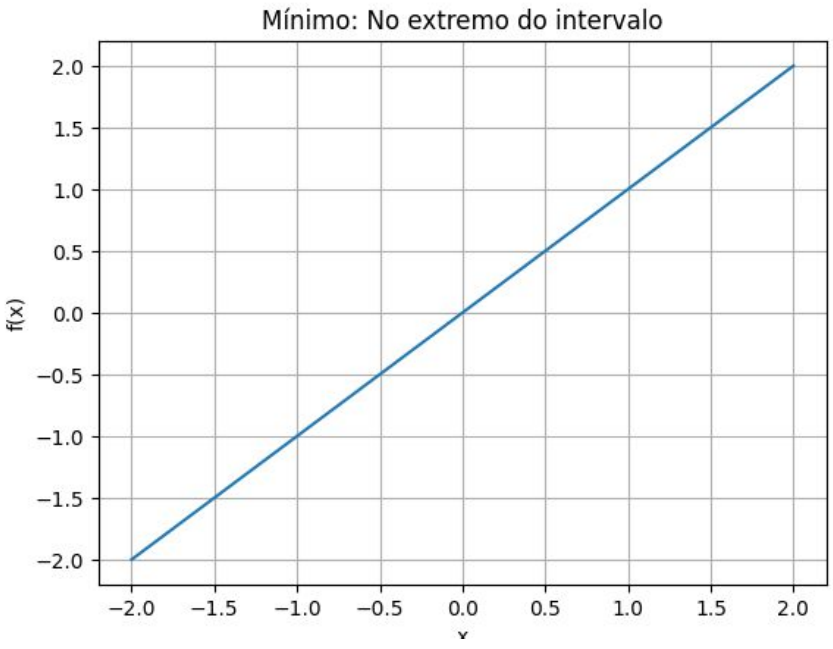
Pontos onde a derivada é zero ou não está definida é denominado de ponto crítico (***critical points***)

INPE
PGCAP

Programa
Queimadas

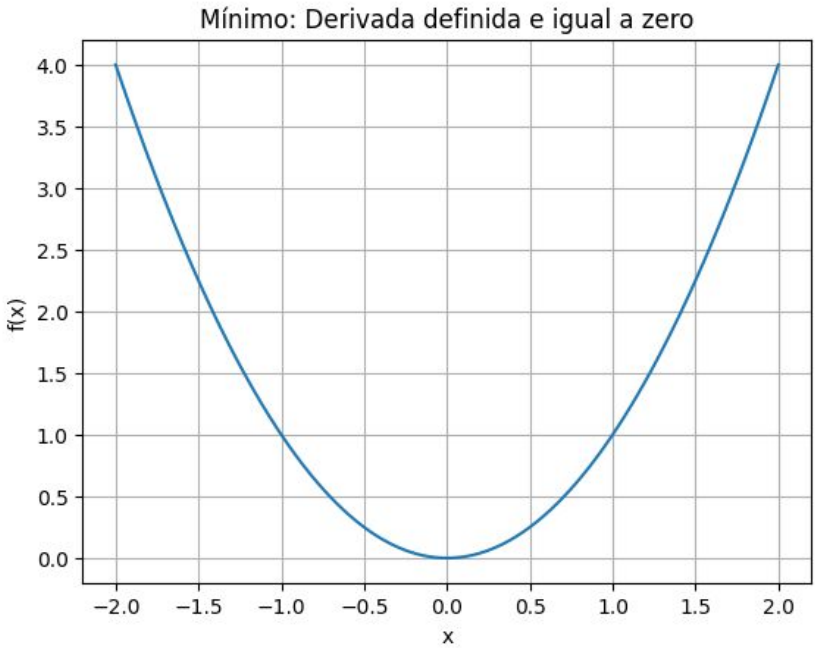
1. Condição de otimalidade

Mínimo no extremo do intervalo.



1. Condição de otimalidade

Mínimo onde a derivada é nula.



INPE
PGCAP

Programa
Queimadas

1. Condição de otimalidade

Mínimo em uma quina



1. Condição de otimalidade

Local de derivada nula que não é mínimo (nem máximo)



INPE
PGCAP

Programa
Queimadas

1. Condição de otimalidade

Então como determinar o comportamento da função ao redor de um ponto *c*? **R:** Avaliam-se tanto a primeira como a segunda derivada.

Se $f'(c) = 0$, então c *pode ser* um minimizador.

Se $f''(c) > 0$, então c = x*, ou seja, um minimizador.

Para provar, a suposição necessária é que $f''(x)$ precisa ser contínua em um intervalo aberto contendo *c*, ou seja, na vizinhança de *c*.

1. Condição de otimalidade

Se *f''(x)* é contínua e positiva em uma vizinhança de *c* e, ao mesmo tempo, *f'(x)* é zero em *c*, isso significa que *f'(x)* está crescendo e que passa de − para +, ou seja, a função estava decrescendo e depois crescendo e o ponto de transição é justamente *c* Logo, à esquerda de *c*, nos pontos x_e

$$f(x_e) \geq f(c)$$

INPE
PGCAP

Programa
Queimadas

1. Condição de otimalidade

À direita de *c*, nos pontos x_d

$$f(x_d) \geq f(c)$$

O que implica justamente em c = x* ser um minimizador.

Nos casos em que a segunda derivada é igual a zero ou não está definida não se pode afirmar que há um mínimo (ou máximo).

De modo análogo, se *f''(c) <0* é contínua numa vizinhança de *c*, então *c* é um máximo local.

1. Condição de otimalidade

Exemplo: Avaliar *f(x) = cos(x)* em c = π.

Solução:

Calculando-se a derivada da função e avaliando-se em c = π

$$f'(x) = - sen(x)$$

$$f'(\pi) = - sen(\pi) = 0 \quad (\underline{\text{pode ser}} \text{ um extremo})$$

Calculando-se a segunda derivada, tem-se:

$$f''(x) = - cos(x)$$

INPE
PGCAP

Programa
Queimadas

1. Condição de otimalidade

Exemplo: (continuação)

como -

$$-cos(\pi) = 1$$

e

$$-cos(\pi + \varepsilon) > 0 , \quad \varepsilon \in]\pi/2 , -\pi/2[$$

então $c = x^* = \pi$ é um mínimo local.

1. Condição de otimalidade

Exemplo: Muitos fabricantes de enlatados desejam reduzir ao máximo o material utilizado no revestimento de latas cilíndricas. Calcular a altura e o raio de uma lata de volume V de modo a minimizar a superfície de material utilizado em sua construção.

Resolução: Escrevendo as equações para o volume da lata e obtendo-se o relacionamento entre *h* e *r*.

$$V = \pi r^2 h \quad \Rightarrow \quad h = \frac{V}{\pi r^2}$$

INPE
PGCAP

Programa
Queimadas

1. Condição de otimalidade

Exemplo: (latas cilíndricas)

A superfície total externa da lata é dada por

$$S = 2\pi r h + 2\pi r^2$$

$$S = \frac{2\pi r V}{\pi r^2} + 2\pi r^2$$

$$S = 2V r^{-1} + 2\pi r^2$$

1. Condição de otimalidade

Exemplo: (latas cilíndricas)

Aplicando-se a condição da primeira derivada:

$$\frac{dS}{dr} = -\frac{2V}{r^2} + 4\pi r$$

$$-\frac{2V}{r^2} + 4\pi r = 0$$

Resolvendo-se obtém-se

$$r = \sqrt[3]{\frac{V}{2\pi}}$$

INPE
PGCAP

Programa
Queimadas

1. Condição de otimalidade

Exemplo: (latas cilíndricas)

Supondo-se, por exemplo, uma lata com V = 300ml = 3 x 10-4 m3, tem-se $r \approx 3.63$ cm e $h \approx 7.25$ cm.

Note-se que a altura da lata é aproximadamente igual ao dobro do raio da própria lata (esse resultado pode ser provado utilizando-se os multiplicadores de lagrange).

1. Condição de otimalidade

Exemplo: (latas cilíndricas)





INPE
PGCAP

Programa
Queimadas

1. Condição de otimalidade

Para o caso multivariável, pode-se fazer o teste de suficiência para verificar se a solução candidata é um mínimo local estrito.

$$\nabla f(\boldsymbol{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \cdots \\ \frac{\partial f}{\partial x_n} \end{bmatrix} \Rightarrow \nabla f(\boldsymbol{x}) = \mathbf{0} = \begin{bmatrix} 0 \\ 0 \\ \cdots \\ 0 \end{bmatrix}$$

1. Condição de otimalidade

Para o caso multivariável, pode-se fazer o teste de suficiência para verificar se a solução candidata é um mínimo local estrito.

$$H_f(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \cdots & \cdots & \cdots & \cdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

$$H_f(x) \succ 0$$

INPE
PGCAP

Programa
Queimadas

1. Condição de otimalidade

Exemplo: Seja *f(x)* = $x_1^2 + x_2^2$, provar que o ponto $[0, 0]^T$ é um mínimo local.

O vetor gradiente é dado por.

$$\nabla f(\boldsymbol{x}) = \begin{bmatrix} 2x_1 \\ 2x_2 \end{bmatrix}$$

No ponto $[0, 0]^T$, o valor do gradiente é:

$$\nabla f(\mathbf{0}) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

1. Condição de otimalidade

Exemplo:(CONT) A hessiana é dada por

$$H_f(x) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

Condição de positiva definida:

$$\boldsymbol{v}^T H_f(x)\boldsymbol{v} = [a, b] \begin{bmatrix} 2a \\ 2b \end{bmatrix}$$

$$\boldsymbol{v}^T H_f(x)\boldsymbol{v} = 2a^2 + 2b^2 > 0$$

INPE
PGCAP

Programa
Queimadas

2. Método da descida do gradiente

Intuição Geral

O método da descida do gradiente baseia-se no fato de que o vetor gradiente aponta sempre na direção de maior crescimento da função. Dessa forma, variações na direção contrária apontam na direção de maior decrescimento. Portanto, ajustar os valores as variáveis de decisão na direção oposta à do gradiente fará com que a função objetivo diminua.

2. Método da descida do gradiente

Derivação para o caso de uma função de variável única

A derivação do método da descida do gradiente pode ser feita utilizando-se a aproximação linear de uma função

$$\frac{f(x+h) - f(x)}{h} \approx f'(x)$$

INPE
PGCAP

Programa
Queimadas

2. Método da descida do gradiente

Derivação para o caso de uma função de variável única

$$f(x+h) - f(x) \approx hf'(x)$$

Como é desejada a diminuição da função, deve-se ter

$$f(x+h) < f(x)$$

Ou seja,

$$f(x+h) - f(x) < 0$$

2. Método da descida do gradiente

Derivação para o caso de uma função de variável única

Ou seja, o produto *hf'(x)* deve ser negativo.

$$hf'(x) < 0$$

Como consequência a variação de *x* pode ser escrita como

$$h = \Delta x = x_{k+1} - x_k = df'(x)$$

sendo que *d* só possui as possibilidades *{+1, -1}*.

INPE
PGCAP

Programa
Queimadas

2. Método da descida do gradiente

Derivação para o caso de uma função de variável única

Para *d* = *1*, ou seja, na mesma direção de *f'(x)*

$$x_{k+1} - x_k = +1f'(x)$$

Para essa primeira situação, a consequência é

$$hf'(x) = f'(x)^2 > 0$$

O que acarreta o crescimento da função.

2. Método da descida do gradiente

Derivação para o caso de uma função de variável única

Para *d* = - *1*, ou seja, na direção oposta à *f'(x)*

$$x_{k+1} - x_k = -1 f'(x)$$

Para essa segunda condição, a consequência é

$$h f'(x) = -f'(x)^2 < 0$$

O que acarreta a diminuição da função.

$$f(x_{k-1}) < f(x_k)$$

INPE
PGCAP

Programa
Queimadas

2. Método da descida do gradiente

Derivação para o caso multidimensional

Quando ***x*** é um vetor, a prova de que a máxima variação se dá na direção do gradiente (e de que a mínima variação se dá na direção oposta) é feita utilizando-se o conceito de derivada direcional.

$$D_u f(\boldsymbol{x}) = \nabla f(\boldsymbol{u}) \cdot \boldsymbol{u}$$

Nessa fórmula, ***u*** é um vetor unitário (i.e., norma unitária e que só interessa a direção).

2. Método da descida do gradiente

Derivação para o caso multidimensional

O produto escalar pode ser reescrito como

$$D_u f(\boldsymbol{x}) = |\nabla f(\boldsymbol{u})||u| \cos(\theta)$$

esse produto é máximo quando $\theta = 0$, ou seja, quando os vetores estão alinhados e $\boldsymbol{u}$ aponta na mesma direção do vetor gradiente.

INPE
PGCAP

Programa
Queimadas

2. Método da descida do gradiente

Derivação para o caso multidimensional

Para se verificar o máximo valor da derivada direcional, basta escolher

$$\boldsymbol{u} = \frac{\nabla f(\boldsymbol{x})}{\|f(\boldsymbol{x})\|}$$

e utilizar a desigualdade de Cauchy-Schwarz aplicada à derivada direcional:

$$\|D_u f(\boldsymbol{x})\| \leq \|\nabla f(\boldsymbol{x})\| \|\boldsymbol{u}\|$$

2. Método da descida do gradiente

Derivação para o caso multidimensional

Substituindo-se o valor de ***u***, tem-se

$$\|D_u f(\boldsymbol{x})\| \leq \|\nabla f(\boldsymbol{x})\| \frac{\|\nabla f(\boldsymbol{x})\|}{\|f(\boldsymbol{x})\|}$$

ou seja,

$$\|D_u f(\boldsymbol{x})\| \leq \|\nabla f(\boldsymbol{x})\|$$

De onde se conclui que a magnitude máxima de variação da função se dá na direção do gradiente.

INPE
PGCAP

Programa
Queimadas

2. Método da descida do gradiente

Detalhes de Implementação

Tipicamente o método do gradiente é aplicado a um conjunto de N pontos e de acordo com uma certa função objetivo f(x).

Para cada ponto, calcula-se o gradiente correspondente e, posteriormente, aplica-se uma correção que é dada pela média dos gradientes individuais das amostras.

2. Método da descida do gradiente

Descrição Algorítmica:

1. Calcular o gradiente por amostra

$$\nabla_i f(\boldsymbol{x})_{x=x_i}$$

2. Calcular o gradiente médio

$$\nabla f(\boldsymbol{x}) = \frac{1}{N} \sum_{i=1}^{N} \nabla_i f(\boldsymbol{x})_{x=x_i}$$

3. Ajustar o valor de $\boldsymbol{x}$ (parâmetros)

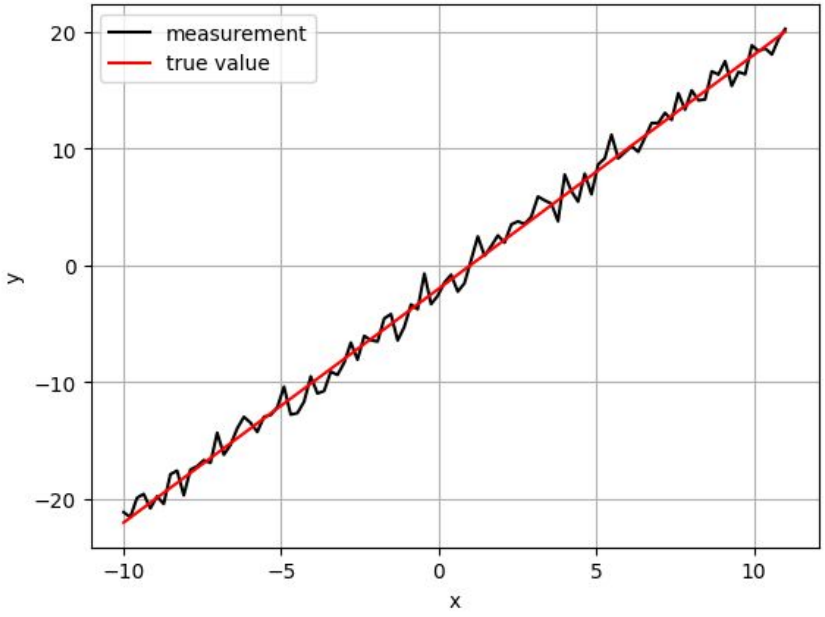
$$\boldsymbol{x_k} = \boldsymbol{x_{k-1}} - \eta \nabla f(\boldsymbol{x})$$

INPE
PGCAP

Programa
Queimadas

2. Método da descida do gradiente

Estudo de caso: Regressão linear com dados ruidosos



2. Método da descida do gradiente

Estudo de caso: Regressão linear com dados ruidosos

Função de custo (J):

$$f(a,b) = J(a,b) = \frac{1}{2N}\sum_{i=1}^{N}(y_m - \hat{y})^2$$

Número de amostras: 100

Número de parâmetros a serem ajustados: 2

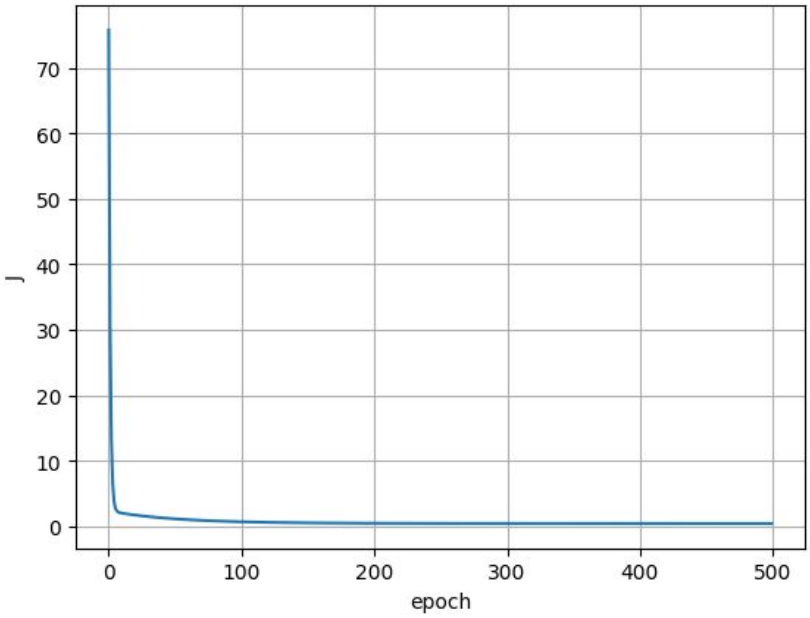
$$\hat{y} = ax + b$$

INPE
PGCAP

Programa
Queimadas

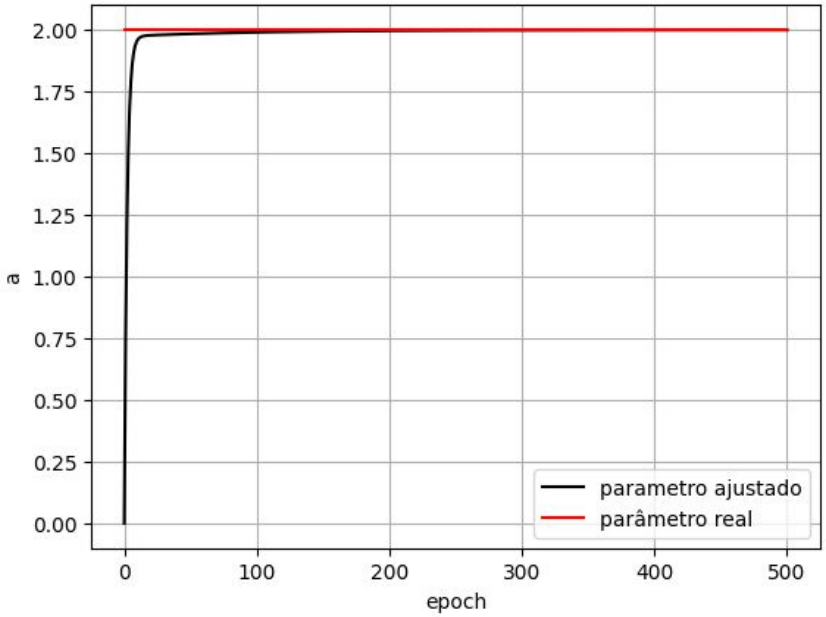
2. Método da descida do gradiente

Estudo de caso: Regressão linear com dados ruidosos



2. Método da descida do gradiente

Estudo de caso: Regressão linear com dados ruidosos

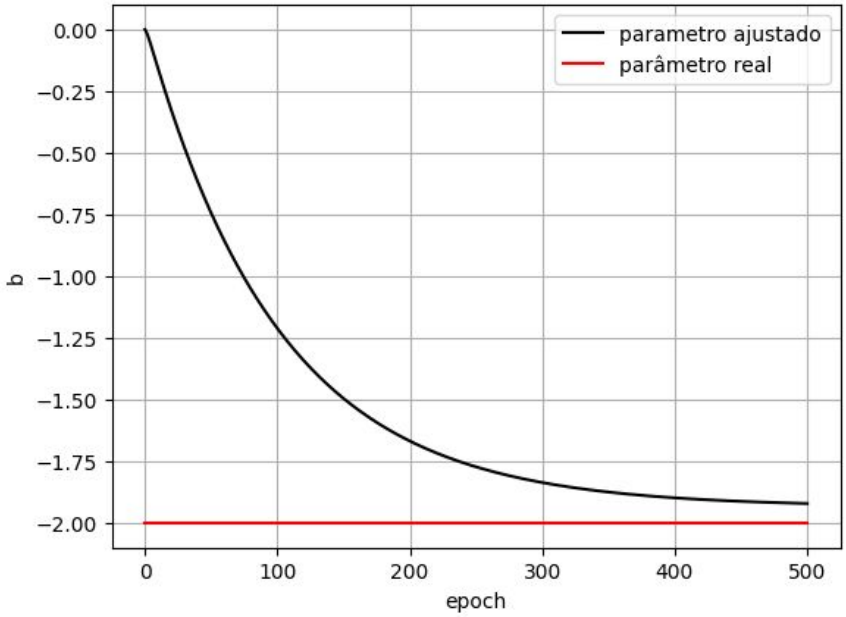


INPE
PGCAP

Programa
Queimadas

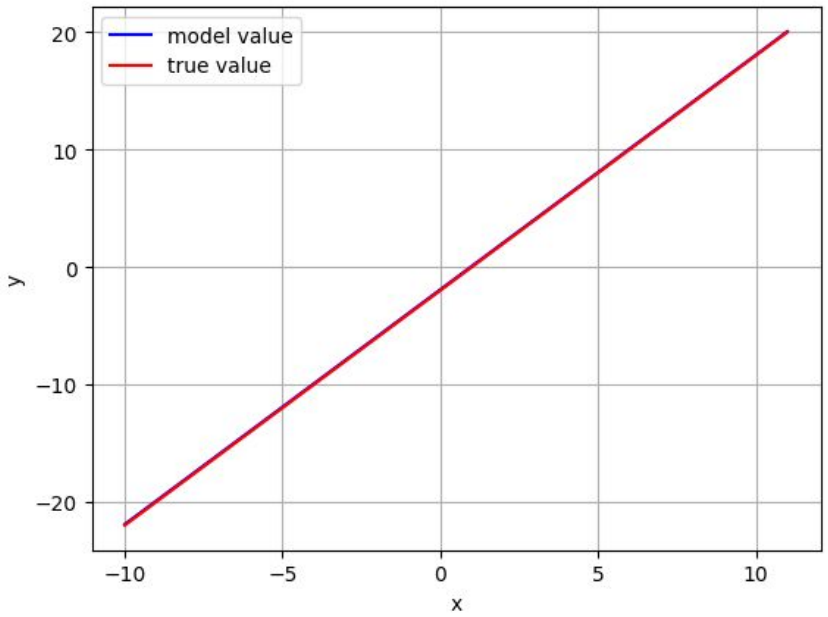
2. Método da descida do gradiente

Estudo de caso: Regressão linear com dados ruidosos



2. Método da descida do gradiente

Estudo de caso: Regressão linear com dados ruidosos



INPE
PGCAP

Programa
Queimadas

2. Método da descida do gradiente

Considerações adicionais:

O tamanho do passo, η , pode não ser adequado à resolução do problema. Nesses casos, pode-se utilizar o procedimento denominado de *backtracking* com condição de Armijo.

Basicamente, o procedimento consiste na avaliação da redução potencial da função e ajuste (redução) do passo utilizado na alteração dos parâmetros.

2. Método da descida do gradiente

Considerações adicionais:

1. Avaliar

$$f(\boldsymbol{x_k} - \eta_k \nabla f(\boldsymbol{x_k})) \leq f(\boldsymbol{x_k}) - c.\eta_k \|\nabla f(\boldsymbol{x_k})\|^2$$

2. Se a condição não for satisfeita, reduzir o valor do passo e voltar ao passo 1.

$$\eta_k = \beta \eta_k, \qquad 0 < \beta < 1$$

3. Se for satisfeita, aplicar alteração nos parâmetros.

Obs: valores típicos para *c*: {0.1, 0.01, 0.001}

INPE
PGCAP

Programa
Queimadas

3. Método da descida do gradiente estocástico

Calcular o gradiente médio para só depois efetuar o ajuste dos parâmetros pode ser muito custoso. Pensando nisso, foi proposto o método do gradiente estocástico.

Nesse método, o ajuste dos parâmetros da função objetivo é alterado a cada ponto, ou seja, para cada amostra x_i faz-se

$$\boldsymbol{x_{i,k}} = \boldsymbol{x_{i,k-1}} - \eta \nabla f(\boldsymbol{x_{i,k-1}})$$

3. Método da descida do gradiente estocástico

Vantagens:

- ✓ Menor memória: não é necessário armazenar todo conjunto de dados ao mesmo tempo.
- ✓ Busca incremental: Atualiza os parâmetros conforme novas amostras são disponibilizadas.
- ✓ Pode progredir rapidamente no início.
- ✓ Alguns ruídos podem ajudar a escapar de mínimos locais.

INPE
PGCAP

Programa
Queimadas

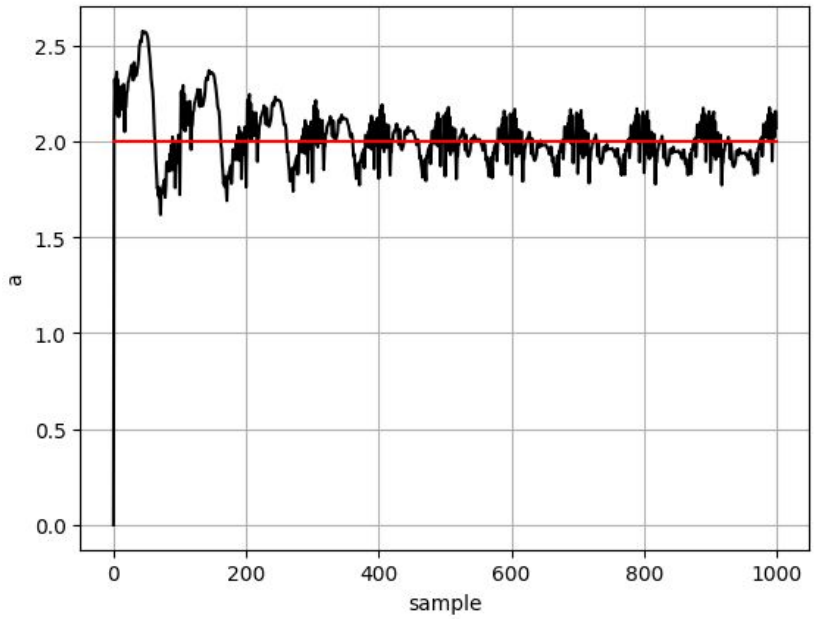
3. Método da descida do gradiente estocástico

Desvantagens:

- ✓ As atualizações são, em geral, mais ruidosas.
- ✓ Pode haver oscilação dos parâmetros ao redor do ótimo.
- ✓ É mais sensível à taxa de aprendizagem.
- ✓ É mais difícil de avaliar a convergência quando se consideram as atualizações isoladas.

3. Método da descida do gradiente estocástico

Estudo de caso: Regressão linear com dados ruidosos

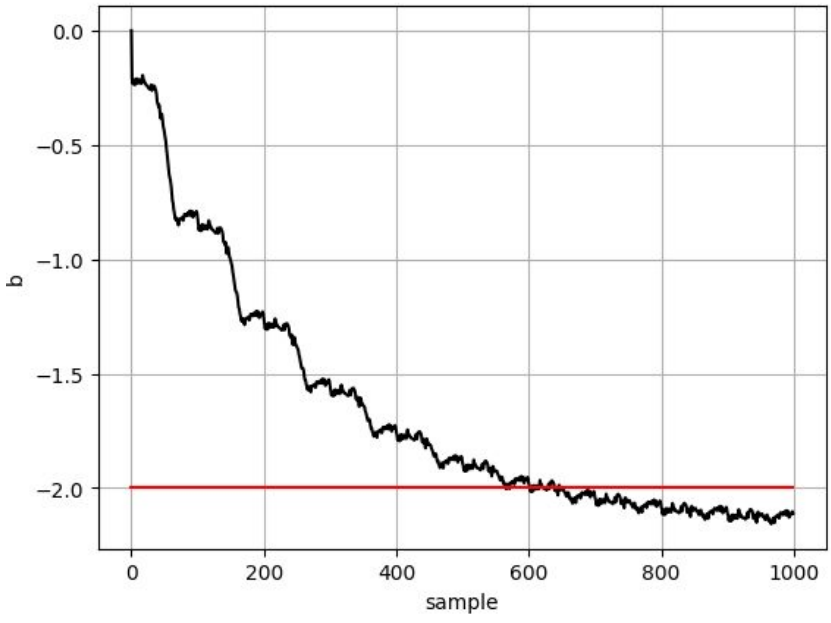


INPE
PGCAP

Programa
Queimadas

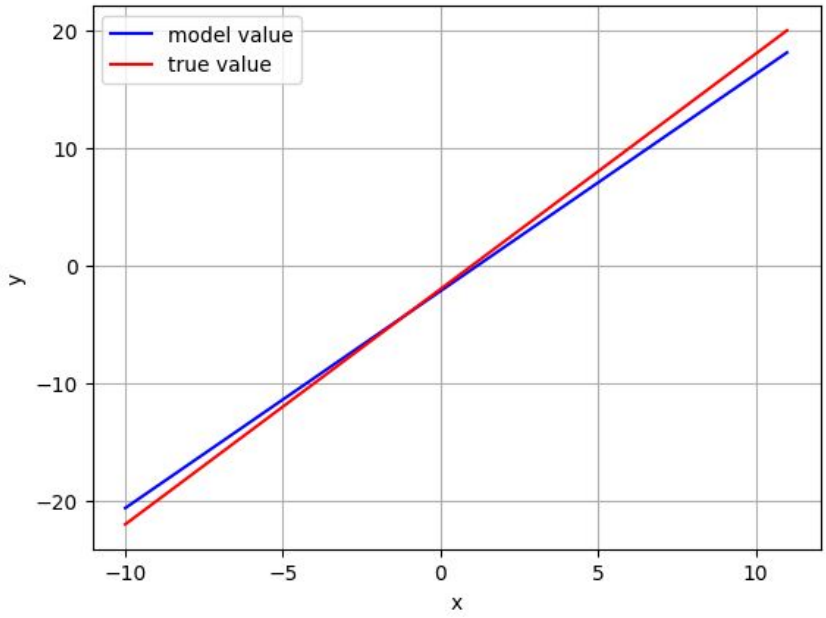
3. Método da descida do gradiente estocástico

Estudo de caso: Regressão linear com dados ruidosos



3. Método da descida do gradiente estocástico

Estudo de caso: Regressão linear com dados ruidosos



INPE
PGCAP

Programa
Queimadas

3. Método da descida do gradiente estocástico

Técnica do *Mini-batch*: Diferentemente do método do gradiente, que utiliza todas as amostras para aplicar o ajuste baseado na média do gradiente, e do método do gradiente estocástico, que atualiza os parâmetros a cada amostra, o método do mini-batch utiliza parte das amostras para aplicar as atualizações.

Como consequência, os ajustes tendem a ser menos ruidosos e com custo inferior ao do método do gradiente tradicional.

3. Método da descida do gradiente estocástico

Técnica do Mini-batch (cont).

Seja *N* o tamanho da amostra e seja *B* o tamanho do Batch, então $\lceil N/B \rceil$ é o número de *batchs* que cabem na amostra.

Exemplo. $N = 10$, $B = 3$ e $\lceil N/B \rceil = 4$

batch_1: amostras 0, 1, 2

batch_2: amostras 3, 4, 5

batch_3: amostras 6, 7, 8

batch_4: amostra 9

INPE
PGCAP

Programa
Queimadas

3. Método da descida do gradiente estocástico

Algoritmo mini-batch

```
Para batch = 0, 1, .., ⌈N/B⌉ faça
    grad ← 0
    amostras ← 0
    Para i = 0, 1, ..., (B-1) faça
        k ← i + batch*B
        Se k < N
            grad ← grad + grad_amostra
            amostras  ← amostras + 1
    grad ← grad/amostras
    Ajustar parâmetros com base em grad
```

4. Algoritmo do gradiente estocástico com momento

O método do gradiente com momento (ou momentum) constitui uma variação do gradiente que faz uso de memória para armazenar as direções anteriores de variação dos parâmetros.

Recebe esse nome por analogia ao momento linear da física (**p** = m.***v***)

INPE
PGCAP

Programa
Queimadas

4. Algoritmo do gradiente estocástico com momento

Atualização dos parâmetros:

$$\boldsymbol{v_k} = \beta \boldsymbol{v_{k-1}} + (1 - \beta) \nabla f(\boldsymbol{x_{k-1}})$$

$$\boldsymbol{x_k} = \boldsymbol{x_{k-1}} - \eta \boldsymbol{v_{k-1}}$$

4. Algoritmo do gradiente estocástico com momento

Vantagens:

- ✓ Pode acelerar a convergência em certas situações (e.g.: vales estreitos).
- ✓ Pode reduzir oscilações em determinadas direções.

Desvantagens:

- Pode gerar oscilações, ultrapassando o mínimo.
- Requer um ajuste de parâmetro adicional (β).

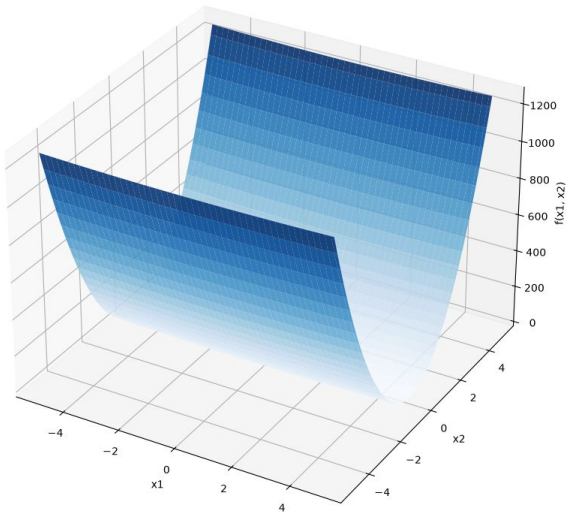
INPE
PGCAP

Programa
Queimadas

4. Algoritmo do gradiente estocástico com momento

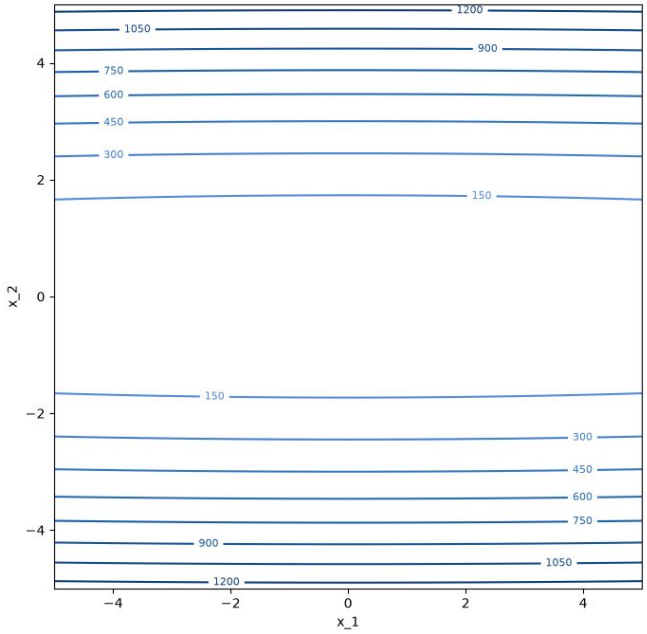
Estudo de Caso: Função com vale estreito:

$$f(x_1,x_2) = 1/2\ (x_1^2 + 100x_2^2)$$



4. Algoritmo do gradiente estocástico com momento

Estudo de Caso: Função com vale estreito:

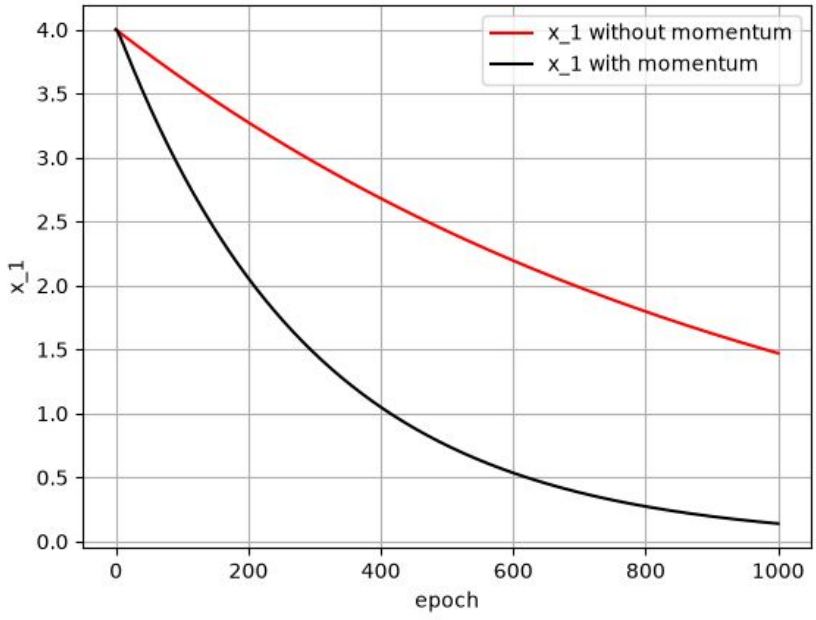


INPE
PGCAP

Programa
Queimadas

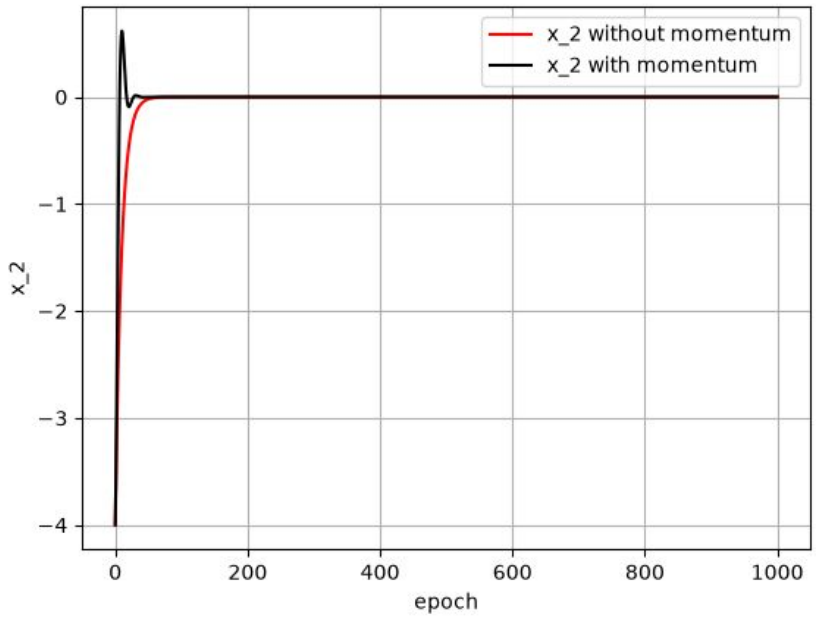
4. Algoritmo do gradiente estocástico com momento

Estudo de Caso: Função com vale estreito:



4. Algoritmo do gradiente estocástico com momento

Estudo de Caso: Função com vale estreito:

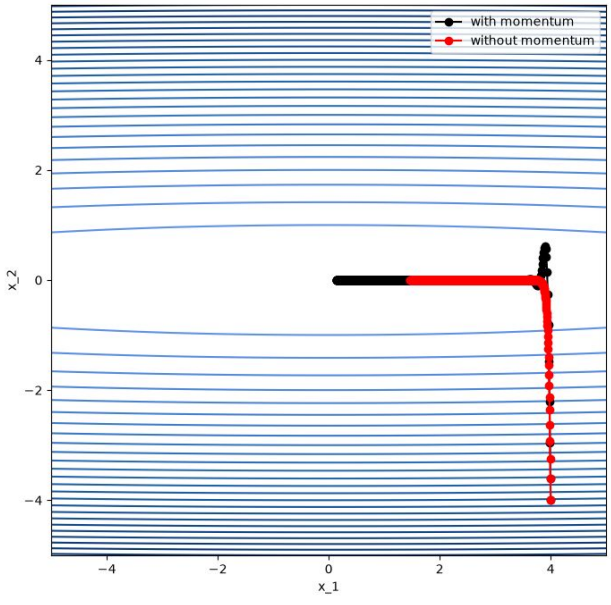


INPE
PGCAP

Programa
Queimadas

4. Algoritmo do gradiente estocástico com momento

Estudo de Caso: Função com vale estreito:



5. Algoritmo do gradiente estocástico com estimação adaptativa de momento (ADAM)

O *Adaptive Moment Estimation* constitui uma variação do método do momento que utiliza tanto uma média dos gradientes (primeiro momento) como uma média dos quadrados dos gradientes (segundo momento).

Inclui a correção de viés para compensar o fato dos momentos iniciais serem zero.

INPE
PGCAP

Programa
Queimadas

5. Algoritmo do gradiente estocástico com estimação adaptativa de momento (ADAM)

Ajuste dos parâmetros:

Primeiro momento:

$$\boldsymbol{m_k} = \beta_1 \boldsymbol{m_{k-1}} + (1 - \beta_1)\nabla f(\boldsymbol{x_{k-1}})$$

Segundo momento:

$$\boldsymbol{v_k} = \beta_2 \boldsymbol{v_{k-1}} + (1 - \beta_2)\nabla^2 f(\boldsymbol{x_{k-1}})$$

5. Algoritmo do gradiente estocástico com estimação adaptativa de momento (ADAM)

Ajuste dos parâmetros:

Correção de viés e ajuste de parâmetros:

$$\hat{m}_k = \frac{m_k}{(1-\beta_1^k)}$$

$$\hat{v}_k = \frac{v_k}{(1-\beta_2^k)}$$

$$x_k = x_{k-1} - \eta \frac{\hat{m}_k}{(\sqrt{v_k} + \epsilon)}$$

INPE
PGCAP

Programa
Queimadas

5. Algoritmo do gradiente estocástico com estimação adaptativa de momento (ADAM)

Vantagens:

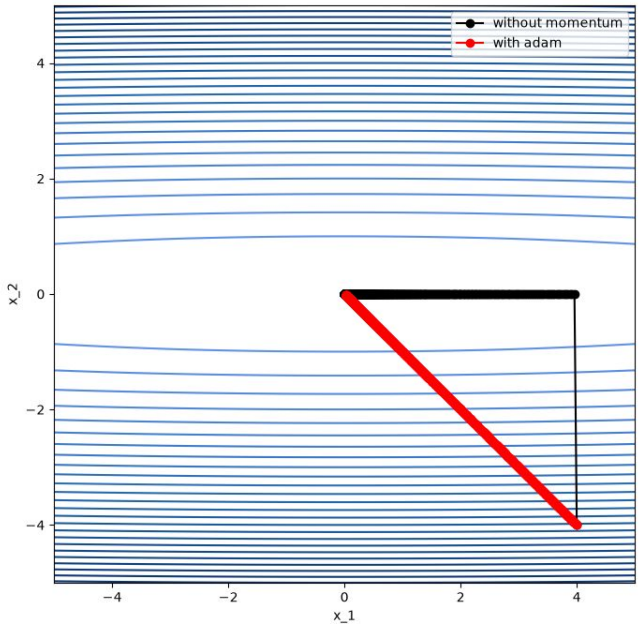
- ✓ Ajuste adaptativo da taxa de variação de cada parâmetro.
- ✓ Apresenta convergência que, em geral, é rápida.

Desvantagens:

- Exigência maior de memória.
- Exige ajuste de um número maior de parâmetros (maior risco de não convergência para o ótimo.

5. Algoritmo do gradiente estocástico com estimação adaptativa de momento (ADAM)

Estudo de caso: Função com vale estreito:



$$f(x_1,x_2) = 1/2\ (x_1^2 + 100x_2^2)$$

INPE
PGCAP

Programa
Queimadas

6. Variantes: RMSProp, Adagrad e AdamW.

RMSProp: O método Root Mean Square Propagation é uma variante que atualiza os parâmetros de acordo com as médias dos quadrados dos gradientes. É útil para o ajuste de redes neurais grandes difíceis de sintonizar os hiperparâmetros.

$$\boldsymbol{v_k} = \beta \boldsymbol{v_{k-1}} + (1-\beta)\nabla^2 f(\boldsymbol{x_{k-1}})$$

$$\boldsymbol{x_k} = \boldsymbol{x_{k-1}} - \eta \frac{\nabla f(\boldsymbol{x_{k-1}})}{(\sqrt{\boldsymbol{v_k}} + \epsilon)}$$

6. Variantes: RMSProp, Adagrad e AdamW.

Adagrad: Método que só acumula as magnitudes dos gradientes e utiliza o ajuste do passo. Útil para problemas com características esparsas (e.g. modelo BOW PLN).

$$G_k = G_{k-1} + \nabla^2 f(x_{k-1})$$

$$x_k = x_{k-1} - \eta \frac{\nabla f(x_{k-1})}{(\sqrt{G_k} + \epsilon)}$$

INPE
PGCAP

Programa
Queimadas

6. Variantes: RMSProp, Adagrad e AdamW.

AdamW: Similar ao método Adam, mas que utiliza decréscimo de parâmetros (*weight decay*).

Trata-se de uma estratégia que permite tratar de maneira melhor a regularização, ou seja, que "desencoraja" valores excessivamente grandes e, como consequência, evita o fenômeno do *overfitting*.

Para um caso de ajuste de parâmetros de modelo, tem-se:

$$f(x) = \frac{1}{2N} \sum_{i=1}^{N} (f(x) - \hat{f}(x))^2 + \frac{\lambda}{2} \|x\|^2$$

6. Variantes: RMSProp, Adagrad e AdamW.

AdamW: Ajuste dos parâmetros. Notar que o último termo da fórmula força x_k a assumir valores baixos.

$$x_k = x_{k-1} - \eta \nabla f(x_{k-1}) - \eta \lambda x_{k-1}$$

INPE
PGCAP

Programa
Queimadas

7. Estudo de Caso: Detecção de vegetação usando bandas visíveis (RGB)

Problema: Considerando as bandas visíveis, RGB, classificar os pixels da imagem como pertencendo a duas classes: **Vegetação** ou **Não Vegetação.**

Função a ser minimizada: Somatório da Entropia cruzada (Cross entropy)

$$J(\theta) = \sum_{k=1}^{N} L_k(\theta)$$

$$L_k(\theta) = -y_k \ln\left(\hat{y}_k(\theta)\right) - (1 - y_k) \ln\left(1 - \hat{y}_k(\theta)\right)$$

7. Estudo de Caso: Detecção de vegetação usando bandas visíveis (RGB)

Imagem de Entrada:



INPE
PGCAP

Programa
Queimadas

7. Estudo de Caso: Detecção de vegetação usando bandas visíveis (RGB)

Modelo de previsão de classe: Utiliza a função logística.

Entradas: bandas RGB

Saída: Probabilidade de pertencer à classe.

$$\boldsymbol{x_k} = \begin{bmatrix} R \\ G \\ B \\ 1 \end{bmatrix} \quad \boldsymbol{\theta}_k = \begin{bmatrix} a \\ b \\ c \\ d \end{bmatrix} \quad y_k = \frac{1}{1 + e^{-\boldsymbol{\theta}^T \boldsymbol{x_k}}} = P(\text{vegetação}|RGB)$$

7. Estudo de Caso: Detecção de vegetação usando bandas visíveis (RGB)

Resultado matematicamente conveniente: Os gradientes das saídas são proporcionais às probabilidades de classificação negativa (para exemplos positivos) ou positiva (para exemplos negativos).

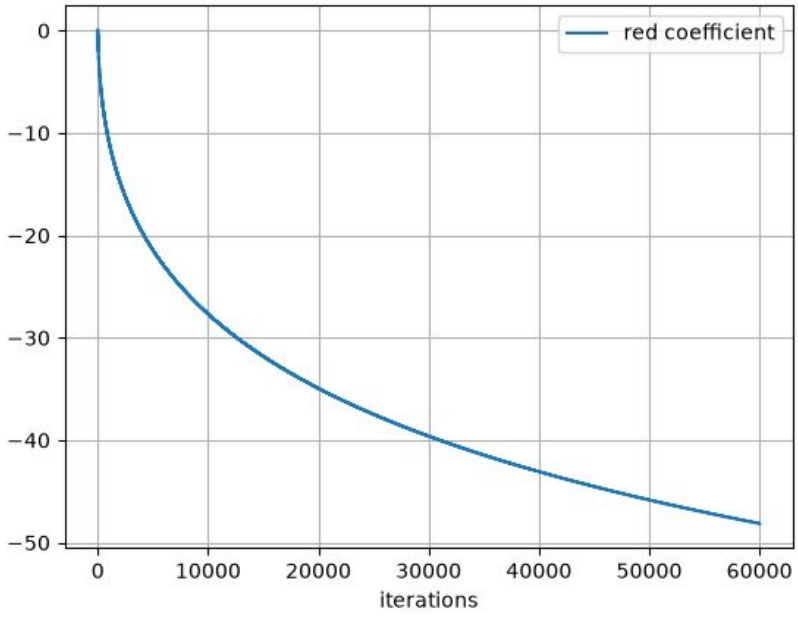
$$\frac{\partial L_k}{\partial \theta_k} = (1 - \hat{y}_k)\boldsymbol{x_k} \qquad \frac{\partial L_k}{\partial \theta_k} = \hat{y}_k \boldsymbol{x_k}$$

INPE
PGCAP

Programa
Queimadas

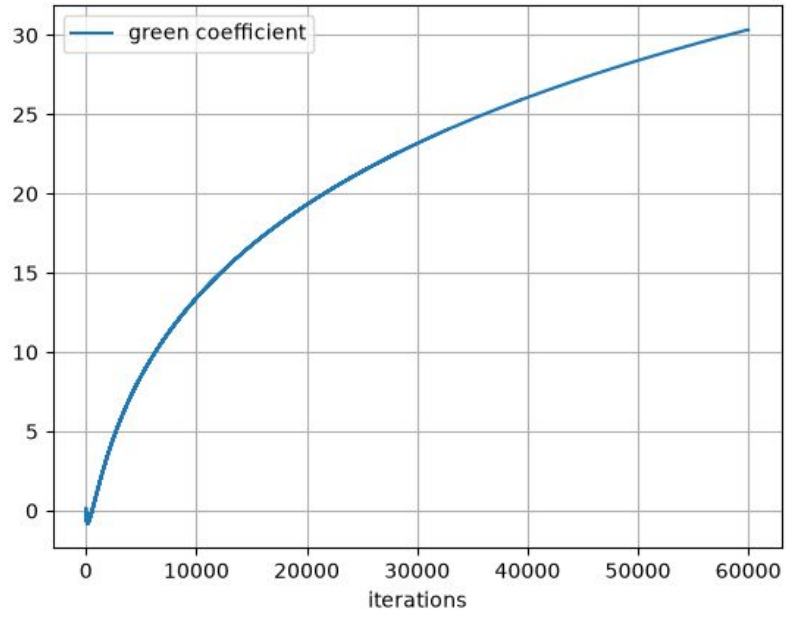
7. Estudo de Caso: Detecção de vegetação usando bandas visíveis (RGB)

Resultado:



7. Estudo de Caso: Detecção de vegetação usando bandas visíveis (RGB)

Resultado:

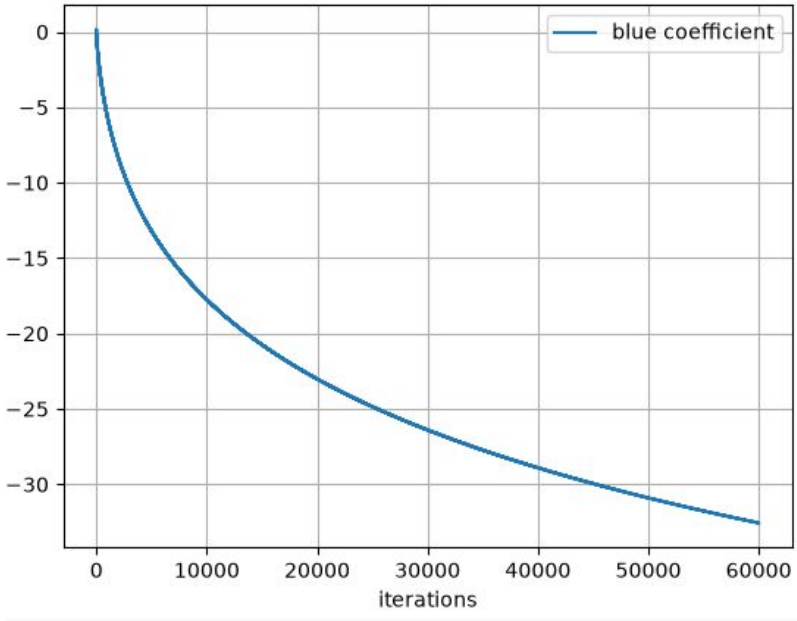


INPE
PGCAP

Programa
Queimadas

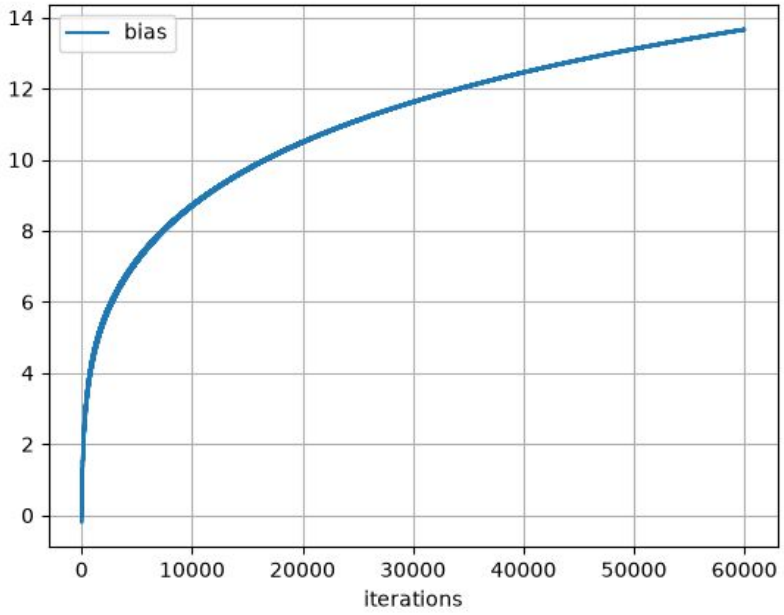
7. Estudo de Caso: Detecção de vegetação usando bandas visíveis (RGB)

Resultado:



7. Estudo de Caso: Detecção de vegetação usando bandas visíveis (RGB)

Resultado:



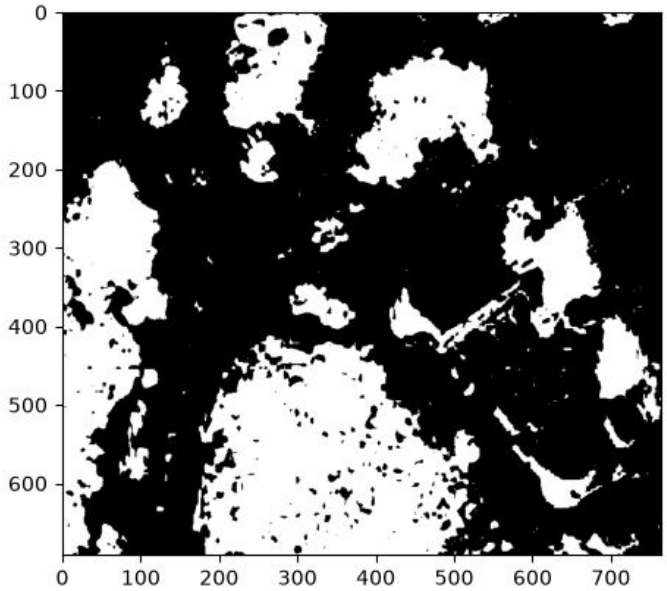
INPE
PGCAP

Programa
Queimadas

7. Estudo de Caso: Detecção de vegetação usando bandas visíveis (RGB)

Resultado:





8. Exercícios e Problemas